
CNN 기반 약품 이미지 분류 및 병용금기(並用禁忌) 검출 시스템

과목명 · 딥러닝 (Team Project 06)

핵심 · 사진 한 장으로 약품을 식별하고, 함께 먹으면 안 되는 조합을 자동 경고

도구 · Python · PyTorch · CNN 100 클래스

1. 소개 (Introduction)

배경 및 문제 제기

- 의약품에는 함께 복용하면 위험한 **병용금기 조합**이 존재하며, 국내에서도 식약처·HIRA가 다수의 금기 조합(약 **1,628쌍**)을 관리합니다.
- 금기 확인의 선행 과제는 **사진 속 개별 약품을 정확히 식별**하는 것입니다. 그러나 한 장에 약품 4개가 다양한 각도로 찍혀 있어, 그대로 다루면 객체 검출(object detection) 문제가 되어 수업 범위를 벗어납니다.

가설 및 목표

- **가설** · 다중 약품 사진을 bbox로 크롭해 단일 약품 이미지로 만들면 **CNN 분류 문제로 환원**할 수 있고, 분류 결과를 성분명으로 변환해 금기 DB와 대조하면 자동 검출이 가능하다.
- **목표** · 약품 **100종**을 분류하는 CNN을 구현하고(**128×128** 입력), 분류 결과를 병용금기 조회 파이프라인과 연결해 **위험한 조합을 자동으로 경고**하는 end-to-end 시스템을 완성한다.


2. 방법 (Methods) — 데이터 및 전처리

데이터 설명

- 원천 · 약품 사진 약 30GB(원본 976×1280), 사진당 약품 4종 + 다중 각도
- 주석 · COCO 포맷 JSON 라벨 **46,117개**, 약품별 bounding box
- 고유 약품코드 · 118종 → **100종** 학습 클래스로 선정
- 전처리 결과 · bbox 크롭으로 단일 약품 **43,350장**

전처리 로직

- 직사각형 bbox 크롭 · 정밀 외곽선(누끼)은 분류 기여가 작아 생략
- 리사이즈·정규화 · 128×128 이중선형 보간 후 **ImageNet 통계**로 픽셀값 정규화.
ImageNet 통계 = 대형 이미지셋의 RGB 채널별 평균·표준편차
($\mu=0.485/0.456/0.406$)로, $(x-\mu)/\sigma$ 변환 시 분포가 평균 0·표준편차 1에 맞춰져 수렴이 빨라짐. 입력을 일정한 크기·분포로 맞추는 **학습 전 표준 전처리**이며, 모델 내부의 BatchNorm과는 별개의 단계.
- **사진(combo) 단위 분할** · 같은 사진의 각도 변형이 train·검증에 섞이는 누수를 막기 위해, 한 사진의 모든 크롭을 train/val/test 한 곳에만 배정 → **70/15/15**, 분할 간 공유 사진 0건.



100종 모두 학습에 사용 · 클래스별 159~1,098장으로 불균형 존재

2-0. 방법 (Methods) — 학습 데이터 샘플

실제 학습에 사용한 단일 약품 크롭 이미지의 예시입니다. 다양한 색·형태·표면 각인을 가진 **100종**을 분류하며, **빨간 테두리**는 프로젝트의 핵심 대상인 **병용금기 약물**입니다.



학습 데이터 샘플 12종 (각 클래스 폴더에서 1장씩) · 빨간 테두리 = 병용금기 3종

2-1. 방법 (Methods) — 학습 클래스 선정 기준

고유 약품코드 118종 중 100종을 다음 우선순위로 선정해, 분류기와 최종 검출 목표를 일관되게 연결했습니다.

선정 우선순위

- ① 병용금기 약물 우선 포함 · 프로젝트 목표가 금기 조합 검출이므로, 데이터셋 내 금기 약물(아질렉트정 등 **3종**)을 반드시 포함 (`class_map.json` 의 `priority: true`).
- ② 나머지는 데이터 수량 상위 순 · 크롭 이미지 수가 많은 약물부터 채워 학습 안정성 확보.

class_idx	약품명	성분 (영문)	이미지 수	구분
0	아질렉트정	rasagiline	159	병용금기
1	울트라셋이알서방정	tramadol	240	병용금기
2	엑티프롤정 60mg	pseudoephedrine	360	병용금기
3 ~ 99	일반 약품 97종	—	데이터 수량 상위	일반

2-2. 방법 (Methods) — DrugCNN 구조

모델 선정 이유

- **CNN** · 약물 식별은 표면의 각인·색·형태 같은 **국소 특징**에 의존 → 가중치 공유 합성곱이 적합하고 평행이동에 강건.
- **블록 구성** · [CONV→BN→ReLU→POOL] 블록 4개 반복 + FC + Dropout. 약 **8.83M 파라미터**(대부분 FC1에 집중).

아키텍처 (채널·해상도 변화)



2-3. 방법 (Methods) — 아키텍처 설계 근거

각 구조 결정은 '식별 정확도 ↔ 학습 비용'의 균형과, 파라미터가 FC1에 집중되는 특성을 고려해 정했습니다.

설계 결정	선택	근거
입력 해상도	128×128	약품 각인·글자를 식별하기에 충분하면서 ImageNet급(224)보다 작아 1~2시간 학습 예산에 맞춘 해상도.
네트워크 깊이	Conv 블록 4개	MaxPool이 절반씩 줄여 128→64→32→16→8. 5블록(4×4)은 정보 과소실, 3블록(16×16)은 FC 입력 폭증 → 4블록이 균형점 .
채널 수	32→64→128→256	해상도가 줄어드는 만큼 채널을 2배씩 늘려 표현력(정보량)을 유지하는 피라미드 구조.
커널·패딩	3×3, pad=1, stride=1	작은 커널을 쌓아 적은 파라미터로 넓은 수용영역 확보. 합성곱은 크기를 보존하고 축소는 Pool이 전담.
Dropout 위치	FC1 뒤 · p=0.5	전체 8.83M 중 FC1이 약 8.39M(95%) — 과적합 위험이 가장 큰 층을 정조준해 정규화.
정규화	BatchNorm (각 conv 뒤)	층별 입력 분포를 안정화해 수렴을 가속하고 그래디언트를 안정시킴.

→ 핵심은 **파라미터의 약 95%가 FC1에 몰린다**는 점입니다. 그래서 Dropout을 정확히 그 지점에 두고, 합성곱부는 작은 커널·풀링으로 가볍게 유지했습니다.

2-3-1. 방법 (Methods) — 설계 근거 심화

앞 장의 구조 결정에 더해, 메모리·해석 관점의 설계 근거를 '입증된 값'과 '관례에서 따라온 값'으로 구분해 정리했습니다.

쟁점	핵심 근거
채널을 2의 거듭제곱으로 (32·64·128·256)	GPU·CPU의 메모리 접근과 벡터 연산은 2의 거듭제곱 크기에서 정렬(alignment)·타일링이 맞아 , 같은 파라미터 수라도 텐서 연산 처리량과 캐시 효율이 높습니다. 임의 값(50·100)보다 최적화된 커널 경로를 타기 쉽습니다.
8×8의 성격 (증명된 최적 아님)	최종 8×8은 실험으로 최적을 입증한 값이 아니라 " 입력 128 + 블록 4개 "의 산술적 귀결(128→64→32→16→8)입니다. 6×6·16×16과의 비교는 수행하지 않았으며 향후 과제로 둡니다.
각 채널이 학습하는 특징 (해석상 추정)	얕은 층(32·64)은 에지·색 대비·질감 등 저수준 보편 특징 , 깊은 층(128·256)은 이를 조합한 윤곽·각인·색+형태 등 고수준 특징 에 반응하는 경향. 단, 채널 1개가 개념 1개에 일대일 대응하지는 않습니다.

2-3-2. 방법 (Methods) — 학습된 채널 시각화 (Feature Maps)


학습된 `best_model.pth` 에 약품 한 장을 통과시켜, 각 블록 채널의 반응을 직접 확인했습니다. 앞 장의 '해석상 추정'을 **실제 관찰로 확인**한 결과입니다.




입력 (128×128) — 표면에 'GIL' 각인이 있는 알약

관찰

- **얕은 층(Block 1, 64×64)** · 채널마다 알약 윤곽·각인 글자·에지·배경 등 저수준 특징에 분담해 반응.
- **깊은 층(Block 4, 8×8)** · 형태를 알아볼 수 없는 추상적 활성 패턴으로 변환 — 위치보다 '존재' 위주의 고수준 특징.
- 일부 채널은 거의 비활성(특징 선택성) → **채널 1개 = 개념 1개**가 아니라 분산 표현.



Block 1 · 저수준(에지·각인·윤곽)



Block 4 · 고수준(추상 활성)

2-4. 방법 (Methods) — 학습 설정 및 하이퍼파라미터 탐색

학습 설정


구성	선택	근거
손실함수	CrossEntropy	다중분류 표준
옵티마이저	Adam	적응적 학습률
정규화	Dropout 0.5 · BN	과적합 억제
증강	Flip·Rotation·Jitter	각도·조명 대응
조기종료	patience = 8	너무 작으면 과소적합, 크면 과적합·낭비 — lr=3e-4의 빠른 수렴상 8이면 충분

2단계 탐색 전략

lr (learning rate · 학습률)은 한 번의 갱신에서 **가중치를 얼마나 크게 움직일지** 정하는 보폭입니다.

너무 크면 최적점을 지나쳐 발산·진동하고, 너무 작으면 수렴이 느립니다.

- **1단계** · 20클래스·20에폭으로 후보 빠른 선별
- **2단계** · 최적 lr=3e-4 로 100클래스 본 학습




스케일에 잘 전이되는 lr·batch·dropout을 1단계에서 확정

3. 결과 (Results) — 분류 성능

평가지표 선정 이유

- **Top-1 정확도(주 지표)** · 약품 식별은 정오답이 명확한 다중분류 → 정확도가 성능을 직관적으로 표현.
- **검증 손실(모델 저장 기준)** · 정확도는 임계값에서 둔감 → 확률 분포 품질을 보는 val_loss를 best 모델 선정에 사용.



100클래스 본 학습 — 과적합 없이 매끄럽게 수렴 (epoch 32 조기종료)


지표	값
최고 검증 정확도	99.18% (epoch 24)
검증 손실	0.0935
조기종료	epoch 32
학습 시간	약 7분 (32 epoch)

단, 이 수치는 **누수 분할 기준의 낙관값**입니다. 누수 없는 사진 단위 분할로 재학습하고 **독립 test셋**에서 Top-1/Top-5-Macro F1-혼동행렬로 재측정합니다(다음 장).

3-1. 결과 (Results) — 병용금지 검출

추론 결과(class_idx)를 `class_map.json` 의 성분명으로 변환하고, 복합 성분을 분리·정규화한 뒤 금기 DB와 매칭합니다. 데이터셋 118종 × 금기 DB 교차 검색 결과 **실제 금기 2쌍**을 검출했습니다.

Contraindication detection in dataset: 2 pairs (rasagiline hub)



약물 A	약물 B	위험
아질렉트정 (rasagiline)	울트라셋이알 (tramadol)	세로토닌증후군· 고혈압위기
엑티프롤정 (pseudoephedrine)	아질렉트정 (rasagiline)	고혈압·빈맥

분류 → 성분명 변환 → 금기 조회로 이어지는 **end-to-end 흐름**이 성립함을 보였습니다. 매칭 로직은 검증셋(16케이스)에서 정확도 **0.625→1.000**으로 강화했습니다(다음 장).

3-2. 결과 (Results) — 실행 예시: 금기 약물 경고

약품 3개가 담긴 복합 사진을 입력하면, 각 약품을 인식하고 **어떤 제품이 함께 위험한지와 그 이유까지** 출력합니다.

```
$ python src/main.py predict --photo combo.png --json combo.json
```

```
[추론] 복합 사진에서 3개 크롭 추출 · 모델 로드 완료 (val_acc=0.9918)
```

[결과] 인식된 약물

- 아질렉트정 (라사길린메실산염) (신뢰도 99.4%)
- 울트라셋이알서방정 (신뢰도 98.7%)
- 액티프롤정 60mg/PTP (신뢰도 97.9%)

[경고] 병용금기 조합 발견! (2건)

아질렉트정 <-> 울트라셋이알서방정

성분: rasagiline <-> tramadol

위험: 고혈압위기, 세로토닌증후군 발생 위험 증가

액티프롤정 60mg <-> 아질렉트정

성분: pseudoephedrine <-> rasagiline

위험: 고혈압, 빈맥 유발

위험 사유는 식약처 병용금기 DB(1,628쌍)의 실제 임상 근거를 그대로 인용해, 사용자가 **왜 위험한지**를 바로 확인할 수 있습니다.

4. 결론 (Conclusion)

요약 및 인사이트

- **문제 재정의의 힘** · 모델을 키우기 전에 객체 검출을 **전처리 크롭을 통한 분류 문제로 환원**한 것이 가장 큰 성능·효율 이득을 냈습니다.
- **병목은 연산이 아니라 I/O** · GPU 활용도를 높인 건 모델 변경이 아니라 데이터 로딩 병렬화(`num_workers=4`)였습니다.
- **지표 해석** · 학습 시 Dropout으로 인한 train/val 지표 역전, val_loss 기준 best 저장 등 학습 로그를 정확히 해석해 신뢰성 있게 모델을 선택했습니다.

달성 요약

100

분류 클래스

70/15/15

누수 없는 분할

2쌍

금기 검출

8.83M

파라미터

기대효과 및 의의

- **복약 안전 향상** · 사진 한 장으로 비전문가도 위험한 약 조합을 즉시 확인 → 오남용·약물 상호작용 사고 예방에 기여할 수 있습니다.
- **확장 가능한 구조** · 분류 클래스와 금기 DB를 넓히면, 더 많은약품·금기 조합으로 그대로 확장되는 파이프라인입니다.
- **이미지 → 의미 연결** · 단순 이미지 분류에 그치지 않고, 분류 결과를 임상 지식(금기 DB)과 연결해 **실제 의사결정에 쓰이는 정보**로 바꿨다는 점이 핵심 의의입니다.

5. 한계점 진단 → 해결

초기 파이프라인의 한계점을 진단하고, 각 항목을 코드로 해결했습니다.

한계점	해결
데이터 누수 · 무작위 분할로 같은 사진 변형이 train·val에 공존	사진(combo) 단위 그룹 분할 → 분할 간 공유 사진 0건
독립 테스트셋 부재 · 일반화 성능 평가 불가	train/val/test 70/15/15 분리, test 전용 평가
금기 검출 검증 약함 · 부분문자열 오매칭	성분 단위 토큰 매칭 + 검증셋 정확도 0.625→1.000
평가지표 부족 · Top-1만 기록	혼동행렬 · Macro F1 · Top-5 추가
클래스 불균형 · 최다/최소 7.0배 미보정	가중 손실(기본) · focal loss · oversampling

5-1. 개선 결과 (재현 가능한 검증)

분할 — 누수 차단 + 테스트셋

분할	이미지	클래스
train	30,444	100
val	6,479	100
test	6,427	100
공유 사진	0건	—

불균형 (7.0배)

가중 손실·focal·oversampling을 플래그로 전환. 소수 클래스 성능은 Macro F1로 확인.

금기 매칭 검증 (16케이스)

방식	Precision	Recall	Acc
기존 substring	0.636	0.778	0.625
개선 token	1.000	1.000	1.000

ephedrine→pseudoephedrine 류 오경보 제거

test 최종 지표 (재학습 후 5_evaluate.py 산출)

Top-1 · Top-5 · Macro F1 · 혼동행렬 → `output/eval/` . 누수 제거 효과를 정직하게 재측정.

감사합니다 · Q&A

CNN 기반 약품 이미지 분류 및 병용금기 검출 시스템 · 딥러닝 Team Project 06